

MASTERCLASS TÉCNICA • 60 MINUTOS

Explorando los LLM por Dentro

Arquitectura interna, tokens, embeddings, atención y criterios de selección

¿Qué ocurre exactamente bajo el capó cuando escribimos una frase a un LLM?

BLOQUE 01

Fundamentos y Evolución

Rompiendo mitos de adopción y analizando la trayectoria técnica de los modelos lingüísticos.

El Mito del "Mejor LLM"

No existe un modelo universal

La selección de un modelo no se basa en modas de marketing, sino en la evaluación precisa de trade-offs técnicos específicos para cada problema de negocio.

Variables de Decisión Críticas

Latencia p95, coste por millón de tokens, seguridad de datos, restricciones de despliegue (API vs On-Premises) y precisión en dominio especializado.

Evolución Tecnológica: De Reglas al Transformer



Sistemas Basados en Reglas

Años 80-90. Gramáticas manuales y lógica simbólica rígida incapaces de escalar ante la ambigüedad humana.



Estadística & RNN/LSTM

N-gramas y redes recurrentes. Memoria secuencial limitada que sufría de desvanecimiento de gradiente a largo plazo.



La Era Transformer

2017 - Presente. Mecanismo de atención total en paralelo. Escalado masivo con internet entero como corpus de entrenamiento.

BLOQUE 02

Anatomía Interna del Transformer

El pipeline técnico: de caracteres en texto plano a representaciones vectoriales y predicción probabilística.

Paso 1: Del Texto a los Tokens (BPE)

- **Byte-Pair Encoding (BPE):** Los LLM no procesan palabras completas, sino subpalabras estadísticas optimizadas por frecuencia.
- **Impacto Lingüístico:** Las lenguas latinas (español) consumen de media un 25-30% más de tokens que el inglés para la misma semántica.
- **Eficiencia de Costes:** El número de tokens determina directamente el coste computacional, la latencia y el uso de la ventana de contexto.



Fragmentación Dinámica

"Gato" → [Gato] (1 token)

"corriendo" → [corr] + [iendo] (2 tokens)

Paso 2: Embeddings Vectoriales

 Vector space representation

- **Espacio Latente Continuo:** Cada identificador numérico de token se transforma en un vector denso de alta dimensión ($\mathbb{R}^N$, típicamente 4096d).
- **Geometría Semántica:** La proximidad espacial representa cercanía conceptual y similitud de significado en el corpus.
- **Álgebra Lineal de Conceptos:** Las relaciones relativas operan vectorialmente (ej. Rey - Hombre + Mujer $\approx$ Reina).

Paso 3: Contexto Dinámico y Self-Attention

Mecanismo Q, K, V

Cada token genera vectores Query (qué busca), Key (qué ofrece) y Value (su contenido). Mediante producto escalar y Softmax, se calcula exactamente a qué palabras prestar atención en la frase.

Ambigüedad Resuelta

La representación vectorial de la palabra "*bank*" cambia dinámicamente si aparece junto a "*loan*" (finanzas) o junto a "*river*" (geografía física).

Paso 4: Bucle Autoregresivo y Generación

- **Predicción Secuencial:** El modelo calcula probabilidades para el siguiente token, selecciona uno y lo reinyecta como entrada para el ciclo siguiente.
- **Parámetro de Temperatura:** Regula la entropía de la distribución de probabilidad (baja = determinista, alta = creativo).
- **Filtros Top-k / Top-p:** Restringen la cola de probabilidad estadística para evitar desvíos o alucinaciones graves en producción.



Inferencia Token a Token

Salida de Logits → Función Softmax (Suma 100%) →
Muestreo Estocástico o Greedy.

BLOQUE 03

Ecosistema y Criterios de Selección

Comparativa objetiva entre APIs gestionadas comerciales y modelos de pesos abiertos (Open Weights).

Comparativa del Ecosistema Actual

Familia / Proveedor	Filosofía Arquitectónica	Implicación Operativa (Ops)
GPT (OpenAI) / Claude (Anthropic)	APIs comerciales gestionadas de circuito cerrado.	ZeroOps, pago por uso por token, dependencia de proveedores externos.
Gemini (Google)	Multimodalidad nativa a escala masiva.	Excelente rendimiento con ingesta compleja de vídeo, audio y texto largo.
Llama (Meta) / Mistral / DeepSeek	Modelos de pesos abiertos (Open-weights).	Control total de privacidad, despliegue en infraestructura propia (CapEx de GPU).

Herramientas de Experimentación



Tiktokenizer

Herramienta empírica para visualizar cómo diferentes codificadores tokenizan código, texto y emojis en tiempo real.



BBycroft 3D Visualizer

Maqueta interactiva para inspeccionar el flujo matricial y las conexiones de atención en un Transformer simplificado.



Validación Empírica

Diseño de pruebas controladas con 50 consultas reales de tu propio caso de uso para medir latencia p95 y precisión.

Patrón Arquitectónico: **RAG vs Fine-Tuning**

Retrieval-Augmented Generation (RAG)

Busca fragmentos externos relevantes en una base de datos vectorial y los inyecta en el contexto. El LLM responde acotado a la evidencia documental, mitigando alucinaciones.

Cuándo aplicar cada estrategia

Usa RAG para bases de conocimiento dinámicas y auditoría estricta de fuentes. Reserva el Fine-Tuning para modificar estilo de respuesta, tono o vocabulario muy especializado.

CIERRE Y CONCLUSIONES

Ingeniería, Datos y Evidencia

Los LLM operan sobre representaciones vectoriales estables. Elegir modelo y arquitectura es un proceso técnico basado en métricas empíricas de tu propio dominio, nunca en fe ciega.

*¿Qué caso de uso llevarás a prueba con métricas reales en tu próximo proyecto? •
Turno de Preguntas (Q&A)*

Image Sources



https://images.stockcake.com/public/4/d/0/4d009b08-abef-4e04-b1c4-b04455762ebb_large/neural-network-visualization-stockcake.jpg

Source: stockcake.com